



PREDIKSI RISIKO GAGAL BAYAR NASABAH DI HOME CREDIT INDONESIA

HOME CREDIT INDONESIA - DATA SCIENTIST

PRESENTED BY BAGUS RAHMADANI





LATAR BELAKANG DAN RUMUSAN MASALAH

Latar Belakang

Home Credit Indonesia merupakan perusahaan pembiayaan yang berorientasi kepada kebutuhan konsumen yang menyediakan berbagai **layanan keuangan**, dari **pembiayaan konsumen hingga proteksi**. Beroperasi sejak **2013**, Home Credit Indonesia telah melayani lebih dari 6,6 juta pelanggan dengan menyediakan layanan keuangan yang transparan dan bertanggung jawab untuk membantu menciptakan kesempatan baru bagi masyarakat. Dengan lebih dari 20.000 titik penjualan di lebih dari 200 kota, Home Credit fokus pada financial inclusion untuk masyarakat unbanked dan underbanked di Indonesia.

Tantangan Bisnis

Sebagai perusahaan pembiayaan konsumen, Home Credit menghadapi tantangan dalam menjaga kesehatan portofolio kredit. Risiko **Non-Performing Loan (NPL)** atau **kredit macet** dapat menyebabkan kerugian finansial yang signifikan bagi perusahaan. Di sisi lain, perusahaan harus tetap melayani pasar luas termasuk masyarakat yang belum memiliki akses ke layanan perbankan tradisional. Tantangan utamanya adalah bagaimana membedakan peminjam yang layak dengan peminjam berisiko tinggi sejak tahap aplikasi, sehingga keputusan approval kredit dapat lebih akurat dan terukur.

Rumusan Masalah

Bagaimana memprediksi pelanggan yang berpotensi mengalami kesulitan pembayaran (default) berdasarkan data aplikasi kredit, sehingga Home Credit dapat mengurangi tingkat NPL dan meningkatkan akurasi persetujuan kredit tanpa mengorbankan misi financial inclusion? Dataset yang tersedia mencakup **307,511 aplikasi kredit** dengan **122 fitur**, namun menghadapi tantangan **imbalanced data** dimana **92% peminjam lancar** dan hanya **8% yang bermasalah**.

Hasil yang Diharapkan

Diharapkan model prediksi dapat **mengidentifikasi calon peminjam berisiko tinggi sejak dini**, **mengurangi tingkat NPL hingga 40-50%**, **serta mengoptimasi proses approval melalui automated scoring system**. Dengan demikian, Home Credit dapat tetap mendukung financial inclusion sambil mengelola risiko kredit secara efektif melalui pendekatan risk-based pricing.






Sumber Data

Analisis ini menggunakan tiga dataset utama dari Home Credit Indonesia. Dataset **Application Train** berisi **307,511** aplikasi kredit dengan **122** fitur yang mencakup informasi **demografis**, **finansial**, dan **riwayat kredit peminjam**. Dataset **Bureau** mencatat **riwayat kredit pelanggan di lembaga keuangan lain**, sedangkan dataset **Previous Application** berisi **riwayat pengajuan kredit sebelumnya di Home Credit**.

Dataset	Rows	Columns
Application Train	307511	122
Application Test	48744	121
Bureau	1716428	17
Previous Application	1670214	37

```
Target distribution (TARGET)
TARGET
0      91.93%
1       8.07%
Name: proportion, dtype: object
```



Variabel Target dan Karakteristik Data

Variabel target yang diprediksi adalah status pembayaran kredit, dimana **0** menunjukkan **peminjam lancar (92% dari total data)** dan **1** menunjukkan **peminjam bermasalah atau default (8% dari total data)**. Ketidakseimbangan kelas ini menjadi tantangan utama dalam pemodelan, karena model cenderung bias terhadap kelas mayoritas.



TEMUAN UTAMA & TINDAKAN BISNIS #1

TARGET	1.000000
BUREAU_DAYS_CREDIT_MEAN	0.089729
DAYS_BIRTH	0.078239
BUREAU_DAYS_CREDIT_MIN	0.075248
REGION_RATING_CLIENT_W_CITY	0.060893
REGION_RATING_CLIENT	0.058899
DAYS_LAST_PHONE_CHANGE	0.055218
DAYS_ID_PUBLISH	0.051457
REG_CITY_NOT_WORK_CITY	0.050994
PREV_DAYS_DECISION_MEAN	0.046864

Skor Kredit Eksternal (EXT_SOURCE) adalah




Faktor Terpenting






Analisis korelasi menunjukkan bahwa **EXT_SOURCE_2** dan **EXT_SOURCE_3** memiliki hubungan terkuat dengan risiko kredit dibandingkan fitur lainnya. Data menunjukkan bahwa peminjam dengan skor eksternal rendah memiliki probabilitas gagal bayar tiga kali lebih tinggi dibandingkan peminjam dengan skor tinggi. Skor eksternal ini diperoleh dari lembaga pemeringkat kredit independen dan terbukti menjadi indikator paling akurat untuk memprediksi perilaku pembayaran.

Tindakan Bisnis yang Direkomendasikan

Berdasarkan temuan ini, disarankan untuk mewajibkan **verifikasi skor kredit eksternal untuk semua aplikasi kredit sebagai langkah pertama dalam proses approval**. Selanjutnya, implementasikan sistem persetujuan bertingkat dimana peminjam dengan **skor tinggi (>0.6)** mendapat auto-approve, skor sedang (0.3-0.6) masuk ke manual review, dan skor rendah (<0.3) mendapat penolakan atau penawaran dengan suku bunga tinggi. Untuk memperkuat sistem ini, Home Credit perlu **menjalin kemitraan strategis** dengan lembaga credit scoring seperti BI Checking dan Pefindo untuk memperoleh data real-time yang lebih akurat.



TEMUAN UTAMA & TINDAKAN BISNIS #2



Stabilitas Pekerjaan dan Usia

Menentukan Tingkat Risiko

Analisis data menunjukkan pola yang jelas terkait stabilitas pekerjaan dan usia peminjam. **Peminjam dengan masa kerja lebih dari 5 tahun** memiliki tingkat kelancaran pembayaran sebesar **85%**, sementara peminjam yang baru bekerja kurang dari 1 tahun menunjukkan tingkat default hingga **22%**. Dari segi usia, kelompok usia **35-50 tahun** memiliki tingkat default terendah hanya **5%**, menunjukkan kematangan finansial yang lebih baik dibandingkan kelompok usia muda.

Tindakan Bisnis yang Direkomendasikan

Berdasarkan temuan ini, perlu dilakukan **segmentasi pelanggan yang lebih terstruktur**. **Segmen prioritas tinggi** adalah pelanggan usia **35-50 tahun** dengan masa kerja **lebih dari 5 tahun**, yang harus mendapat marketing intensif dan penawaran suku bunga kompetitif. **Segmen risiko menengah** yaitu pelanggan **usia muda** namun dengan **pekerjaan stabil** dapat diberi limit kredit bertahap yang meningkat seiring rekam jejak pembayaran. Sementara **segmen risiko tinggi** seperti **fresh graduate** atau yang baru bekerja perlu dipersyaratkan collateral atau guarantor. Untuk meningkatkan portofolio berkualitas, fokuskan campaign marketing ke segmen PNS dan pegawai BUMN yang memiliki stabilitas pekerjaan tinggi, serta wajibkan verifikasi employment dengan surat keterangan kerja dan konfirmasi langsung ke HRD perusahaan.

PRAPEMROSESAN DATA DAN REKAYASA FITUR



	Kolom	Total Missing	Persentase (%)
48	COMMONAREA_AVG	214865	69.87
76	COMMONAREA_MEDI	214865	69.87
62	COMMONAREA_MODE	214865	69.87
56	NONLIVINGAPARTMENTS_AVG	213514	69.43
70	NONLIVINGAPARTMENTS_MODE	213514	69.43
84	NONLIVINGAPARTMENTS_MEDI	213514	69.43
86	FONDKAPREMONT_MODE	210295	68.39
82	LIVINGAPARTMENTS_MEDI	210199	68.35
68	LIVINGAPARTMENTS_MODE	210199	68.35
54	LIVINGAPARTMENTS_AVG	210199	68.35
52	FLOORSMIN_AVG	208642	67.85
80	FLOORSMIN_MEDI	208642	67.85
66	FLOORSMIN_MODE	208642	67.85
47	YEARS_BUILD_AVG	204488	66.50
75	YEARS_BUILD_MEDI	204488	66.50
61	YEARS_BUILD_MODE	204488	66.50
21	OWN_CAR_AGE	202929	65.99
53	LANDAREA_AVG	182590	59.38
81	LANDAREA_MEDI	182590	59.38
67	LANDAREA_MODE	182590	59.38

```
# Hapus kolom dengan missing values > 40%
threshold = 40
cols_to_drop = missing_data[missing_data['Persentase (%)'] > threshold]['kolom'].tolist()

print(f"Kolom yang dihapus (missing > {threshold}%): {len(cols_to_drop)}")
print(cols_to_drop)

# Drop kolom
df_HCI = df_HCI.drop(columns=cols_to_drop)
print(f"\nShape setelah drop kolom: {df_HCI.shape}")

✓ 0.1s

Kolom yang dihapus (missing > 40%): 49
['COMMONAREA_AVG', 'COMMONAREA_MEDI', 'COMMONAREA_MODE', 'NONLIVINGAPARTMENTS_AVG', 'NONLIVINGAPARTMENTS_MODE', 'NONLIVINGAPARTMENTS_MEDI', 'FONDKAPREI']

Shape setelah drop kolom: (307511, 87)
```

Rekayasa Fitur (Feature Engineering)

Untuk meningkatkan kualitas prediksi, dilakukan **transformasi** pada beberapa fitur mentah. Kolom **DAYS_BIRTH** dikonversi menjadi **AGE_YEARS** dengan formula **-DAYS_BIRTH / 365** agar lebih mudah diinterpretasi. Demikian pula **DAYS_EMPLOYED** diubah menjadi **YEARS_EMPLOYED**. Selain itu, dibuat fitur rasio baru seperti **CREDIT_INCOME_RATIO** (*perbandingan jumlah kredit dengan pendapatan*) dan **ANNUITY_INCOME_RATIO** (*perbandingan angsuran dengan pendapatan*) yang terbukti meningkatkan performa model.

```
FEATURE SCALING

Scaling untuk kolom yang belum dinormalisasi (EXT_SOURCE sudah normalized)

# Pisahkan X dan y
x = df_HCI.drop('TARGET', axis=1)
y = df_HCI['TARGET']


# Kolom yang sudah normalized
normalized_cols = ['EXT_SOURCE_2', 'EXT_SOURCE_3', 'REGION_POPULATION_RELATIVE']
cols_to_scale = [col for col in num_cols if col not in normalized_cols and col in x.columns]

# Scaling
scaler = StandardScaler()
x[cols_to_scale] = scaler.fit_transform(x[cols_to_scale])

print(f"Scaling selesai! {len(cols_to_scale)} kolom di-scale.")
print(f"Shape X: {x.shape}, y: {y.shape}")

✓ 0.9s

Scaling selesai! 50 kolom di-scale.
Shape X: (307511, 69), y: (307511,)
```



Penanganan Missing Values

Langkah awal preprocessing adalah **mengidentifikasi dan menangani missing values** yang tersebar di berbagai kolom. Kolom dengan missing values **lebih dari 40% dihapus** dari dataset karena dianggap tidak cukup informatif. Untuk kolom yang tersisa, dilakukan **imputasi** menggunakan nilai median untuk fitur numerik dan modus untuk fitur kategorikal, sehingga tidak ada data yang hilang dalam proses pemodelan.

FEATURE ENGINEERING

Konversi kolom DAYS menjadi lebih mudah dipahami

```
# Konversi DAYS menjadi tahun
df_HCI['AGE_YEARS'] = (-df_HCI['DAYS_BIRTH'] / 365).astype(int)
df_HCI['YEARS_EMPLOYED'] = df_HCI['DAYS_EMPLOYED'].apply(lambda x: -x/365 if x<0 else 0)

# Buat rasio fitur
df_HCI['CREDIT_INCOME_RATIO'] = df_HCI['AMT_CREDIT'] / df_HCI['AMT_INCOME_TOTAL']
df_HCI['ANNUITY_INCOME_RATIO'] = df_HCI['AMT_ANNUITY'] / df_HCI['AMT_INCOME_TOTAL']

print("Feature Engineering selesai!")
print(f"Shape: {df_HCI.shape}")

✓ 0.1s

Feature Engineering selesai!
Shape: (307511, 70)
```

Encoding, Scaling, dan Penanganan

Imbalanced Data

Fitur kategorikal yang berjumlah 6 kolom **di-encode** menggunakan **Label Encoding** agar dapat diproses oleh algoritma machine learning. Fitur numerik yang belum ternormalisasi di-scaling menggunakan **StandardScaler**, kecuali fitur yang sudah normalized seperti **EXT_SOURCE**. Untuk mengatasi masalah **imbalanced data (92:8)**, diterapkan teknik Random **Undersampling** dan **Oversampling (SMOTE)** yang mengubah distribusi kelas menjadi seimbang (**50:50**), sehingga model tidak bias terhadap kelas mayoritas.

PENGEMBANGAN DAN PEMILIHAN MODEL



```
# Buat tabel perbandingan semua model
comparison = pd.DataFrame({
    'Model': ['LR-Original', 'LR-SMOTE', 'LR-Undersampling',
             'RF-Original', 'RF-SMOTE', 'RF-Undersampling'],
    'Accuracy': [
        accuracy_score(y_val, y_pred_original),
        accuracy_score(y_val, y_pred_smote),
        accuracy_score(y_val, y_pred_under),
        accuracy_score(y_val, y_pred_rf_original),
        accuracy_score(y_val, y_pred_rf_smote),
        accuracy_score(y_val, y_pred_rf_under)
    ],
    'ROC-AUC': [
        roc_auc_score(y_val, y_pred_original),
        roc_auc_score(y_val, y_pred_smote),
        roc_auc_score(y_val, y_pred_under),
        roc_auc_score(y_val, y_pred_rf_original),
        roc_auc_score(y_val, y_pred_rf_smote),
        roc_auc_score(y_val, y_pred_rf_under)
    ]
})

print("Perbandingan Semua Model:")
print(comparison)
```

Dalam penelitian ini, dilakukan eksperimen terhadap **6 model** berbeda yang merupakan kombinasi dari 2 algoritma (**Logistic Regression dan Random Forest**) dengan 3 teknik penanganan imbalanced data (**Original, SMOTE, dan Undersampling**). Setelah evaluasi menyeluruh, model final yang dipilih adalah **Logistic Regression dengan teknik Random Undersampling** karena menunjukkan performa terbaik dalam mengidentifikasi peminjam bermasalah.

Perbandingan Semua Model:

	Model	Accuracy	ROC-AUC
0	LR-Original	0.919467	0.505985
1	LR-SMOTE	0.760857	0.611247
2	LR-Undersampling	0.689381	0.684257
3	RF-Original	0.919337	0.500862
4	RF-SMOTE	0.915500	0.508696
5	RF-Undersampling	0.690129	0.677223

Model **Logistic Regression** dengan **Undersampling** dipilih berdasarkan **tiga alasan utama**. **Pertama**, model ini memiliki **ROC-AUC tertinggi sebesar 68.43%**, yang menunjukkan kemampuan diskriminasi terbaik dalam membedakan kelas lancar dan bermasalah. **Kedua**, **Recall untuk kelas bermasalah mencapai 68%**, artinya model dapat mendeteksi 68% peminjam yang berisiko default. **Ketiga**, **model ini interpretable** sehingga mudah dijelaskan kepada stakeholder bisnis. Model menggunakan lebih dari **40 fitur hasil feature engineering** dengan algoritma **Logistic Regression (max_iter=1000, random_state=42)**. **Pipeline preprocessing** mencakup penanganan missing values, feature engineering, encoding, scaling, dan undersampling secara berurutan.


Top 10 Most Important Features:

	Feature	Coefficient
39	EXT_SOURCE_3	2.510438
38	EXT_SOURCE_2	2.078838
8	AMT_GOODS_PRICE	1.018793
6	AMT_CREDIT	0.851046
68	ANNUITY_INCOME_RATIO	0.745147
1	CODE_GENDER	0.425883
15	DAYS_BIRTH	0.375489
2	FLAG_OWN_CAR	0.306099
0	NAME_CONTRACT_TYPE	0.283537
61	PREV_ANNUITY_MEAN	0.261529


Analisis **feature importance** menunjukkan bahwa **5 fitur** teratas yang paling berpengaruh adalah **EXT_SOURCE_2** (*skor kredit eksternal*), **EXT_SOURCE_3** (*skor kredit eksternal alternatif*), **DAYS_BIRTH** (*usia pelanggan*), **DAYS_EMPLOYED** (*masa kerja*), dan **AMT_CREDIT** (*jumlah kredit yang diajukan*). Kelima fitur ini memiliki kontribusi terbesar dalam menentukan prediksi risiko kredit dan menjadi fokus utama dalam proses verifikasi aplikasi.

PERFORMA DAN EVALUASI MODEL


Confusion Matrix



Classification Report



ROC-AUC CURVE



Perbandingan Performa Model

Perbandingan Semua Model:

	Model	Accuracy	ROC-AUC
0	LR-Original	0.919467	0.505985
1	LR-SMOTE	0.760857	0.611247
2	LR-Undersampling	0.689381	0.684257
3	RF-Original	0.919337	0.500862
4	RF-SMOTE	0.915500	0.508696
5	RF-Undersampling	0.690129	0.677223

Hasil evaluasi menunjukkan perbedaan performa yang signifikan antar model. Model LR-Original dan RF-Original memiliki accuracy tinggi mencapai 91.95% dan 91.93%, namun Recall kelas bermasalah sangat rendah hanya 1%, artinya model hampir tidak bisa mendeteksi peminjam berisiko. Model LR-SMOTE menunjukkan peningkatan dengan ROC-AUC 61.12% dan Recall 43%. Model terbaik adalah LR-Undersampling dengan ROC-AUC tertinggi 68.43% dan Recall kelas bermasalah tertinggi 68%.

Mengapa ROC-AUC dan Recall Lebih Penting dari Accuracy

Dalam konteks credit risk, accuracy tinggi tidak selalu berarti model yang baik. Model dengan accuracy 91% namun Recall hanya 1% gagal mendeteksi peminjam bermasalah, sehingga perusahaan tetap mengalami kerugian akibat kredit macet. Yang lebih penting adalah kemampuan model mendeteksi kelas minoritas (peminjam bermasalah), diukur dengan Recall. ROC-AUC mengukur kemampuan model membedakan kedua kelas secara keseluruhan. Dalam bisnis kredit, prinsipnya adalah "better reject good customer than accept bad customer" karena biaya kredit macet jauh lebih mahal daripada kehilangan satu pelanggan potensial.

Trade-off yang Diterima dan Visualisasi Performa

Model final mengalami penurunan accuracy dari 92% menjadi 69%, namun Recall meningkat drastis 67 kali lipat dari 1% menjadi 68%. Trade-off ini dapat diterima karena cost of false negative (menerima peminjam bermasalah) jauh lebih tinggi daripada cost of false positive (menolak peminjam baik). Visualisasi Confusion Matrix menunjukkan peningkatan True Positive rate yang signifikan, ROC-AUC Curve menunjukkan area under curve terbesar untuk model LR-Undersampling, dan Feature Importance chart mengidentifikasi 15 fitur teratas yang paling berkontribusi dalam prediksi.



Strategi Deployment dan Sistem Scoring

Implementasi model ke dalam operasional bisnis dilakukan melalui ***automated credit scoring system*** berbasis 15 fitur terpenting yang telah teridentifikasi. Sistem ini akan mengkategorikan setiap aplikasi kredit ke dalam tiga tingkat risiko: Low Risk (Score >0.7) untuk auto-approve dengan suku bunga rendah, Medium Risk (Score 0.3-0.7) untuk manual review oleh credit analyst, dan High Risk (Score <0.3) untuk penolakan otomatis atau penawaran dengan suku bunga tinggi disertai persyaratan collateral.

Tindakan Operasional yang Direkomendasikan

Untuk memaksimalkan efektivitas model, perlu dilakukan penyesuaian dalam proses operasional. **Prioritas verifikasi** harus difokuskan pada tiga aspek utama secara berurutan: verifikasi **EXT_SOURCE** (*skor kredit eksternal*), verifikasi **employment stability** (*masa kerja dan status pekerjaan*), dan verifikasi **bureau history** (*riwayat kredit di bank lain*). **Marketing focus** diarahkan ke segmen **low-risk** yaitu **PNS, pegawai dengan pekerjaan stabil, dan kelompok usia 35-50 tahun**. **Monitoring performa** model dilakukan secara **monthly** untuk tracking akurasi prediksi, dengan retraining model setiap kuartal menggunakan data terbaru.

Dampak yang Diharapkan

Dengan implementasi model dan rekomendasi bisnis ini, diharapkan terjadi **pengurangan NPL sebesar 40-50% dari tingkat saat ini 8% menjadi 4-5%**, **peningkatan accuracy approval sebesar 68% dalam mengidentifikasi peminjam berisiko**, dan **optimasi resource** untuk manual review sehingga tim credit analyst dapat fokus pada kasus-kasus medium risk yang memerlukan analisis mendalam.



TERIMA KASIH

<https://github.com/Bagus2510/Rakamin-PBI-Home-Credit-Indonesia-Data-Scientist>

